

Proposta de Projeto Final - Fundamentos de Machine Learning

Autora: A. Cristiane R. Lima (Cristie)

Disciplina: Fundamentos de Machine Learning

Curso: Pós-graduação em Ciência de Dados

Data: 16 de agosto de 2025

1. Introdução

A Monkeypox (Mpox) é uma doença emergente monitorada pelo Ministério da Saúde no Brasil. O dataset público disponibilizado pelo DATASUS contém registros de casos notificados, incluindo informações sociodemográficas, clínicas e de evolução. Este projeto visa aplicar modelos de aprendizado supervisionado para prever a variável hospitalização (se o paciente foi ou não hospitalizado), a partir das demais variáveis coletadas.

2. Fundamentação Teórica

Modelos de classificação supervisionados permitem prever categorias a partir de variáveis explicativas. Entre os algoritmos de classificação mais utilizados estão Regressão Logística, Random Forest, Decision Trees, e Support Vector Machines (SVM). Esses modelos serão comparados em termos de acurácia, precisão, recall e F1-score, para avaliar sua aplicabilidade em problemas de saúde pública.

3. Objetivos

3.1 Objetivo Geral

Desenvolver e avaliar modelos de classificação supervisionados capazes de prever hospitalização de casos de Mpox no Brasil.

3.2 Objetivos Específicos

- Pré-processar o dataset da Mpox, incluindo limpeza, tratamento de valores ausentes e codificação de variáveis categóricas.
- Construir diferentes modelos de classificação supervisionados.
- Avaliar o desempenho dos modelos utilizando métricas de classificação.
- Identificar as variáveis mais relevantes para a hospitalização.

4. Metodologia

O projeto seguirá as etapas:

1. Coleta do dataset público do DATASUS (Mpox).
2. Pré-processamento (remoção de outliers, codificação de variáveis categóricas, normalização de variáveis numéricas).
3. Divisão em conjuntos de treino e teste (70%-30%).
4. Treinamento de modelos supervisionados (Regressão Logística, Random Forest, Decision Tree, SVM).
5. Avaliação de desempenho com métricas (acurácia, precisão, recall, F1-score, matriz de confusão).
6. Análise comparativa e discussão dos resultados.

5. Resultados Esperados

Espera-se que os modelos sejam capazes de prever com boa performance a hospitalização de casos de Mpox. Modelos baseados em árvores (Random Forest, Decision Tree) podem se destacar devido à robustez em lidar com variáveis categóricas. Além da predição, será possível identificar quais variáveis têm maior impacto na decisão de hospitalizar, contribuindo para a compreensão dos fatores associados à gravidade da doença.

6. Conclusão

O projeto contribuirá para demonstrar a aplicabilidade de técnicas de Machine Learning em dados de saúde pública brasileiros. A análise do dataset da Mpox permitirá compreender padrões e apoiar políticas de saúde, além de consolidar o aprendizado dos fundamentos de modelos de classificação supervisionados.